# Jawaban Latihan Kisi-kisi UTS

Pembahasan terstruktur, perhitungan tiga desimal, visualisasi, dan sitasi materi kuliah.

5

Topik utama

18

Subbutir

4

Grafik analisis

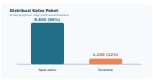
# Daftar Isi


1. 1. Studi Kasus Prediksi Keterlambatan KirimCepat
2. 2. Data Preparation dan Imbalanced Data
3. 3. Feature Selection dan Feature Engineering
4. 4. Decision Tree
5. 5. K-Nearest Neighbors
6. Kesimpulan Singkat


> Jawaban disusun berdasarkan knowledge base mata kuliah. Sitasi menggunakan format ID dokumen dan halaman.

# 1. Studi Kasus Prediksi Keterlambatan KirimCepat

### a. Kategori ML, tugas, target, dan metrik



Distribusi kelas awal menunjukkan imbalance 88% berbanding 12%.

- **Kategori ML:** supervised learning, karena tersedia data berlabel.
- **Jenis tugas:** klasifikasi biner.
- **Target:** status paket, yaitu `terlambat` (kelas positif) atau `tepat waktu` (kelas negatif).
- **Metrik utama: F1-score kelas terlambat**, karena data tidak seimbang dan F1 menyeimbangkan precision dengan recall. Recall kelas terlambat juga perlu dipantau karena false negative berarti paket terlambat tidak diberi peringatan.

Model yang selalu menebak **tepat waktu** menghasilkan:

$$\text{Accuracy} = (8.800)/(10.000) = 0{,}880$$

Walaupun akurasinya **0,880**, model tidak pernah menemukan paket terlambat, sehingga TP = 0, FN = 1.200, dan recall kelas terlambat = 0. Akurasi tidak layak menjadi metrik utama karena kelas mayoritas mendominasi hasil dan menyembunyikan kegagalan total pada kelas yang ingin dideteksi. Materi memberikan pola yang sama: model semua-kelas-mayoritas dapat memiliki akurasi tinggi tetapi recall kelas positif nol. **[ML-P03, hlm. 17–19]**

## b. Fase CRISP-DM yang dikunjungi kembali

1. **Definisi "terlambat" belum disepakati**

Kembali ke fase **Business Understanding**. Tim bisnis dan operasional harus menentukan definisi target yang terukur, misalnya terlambat jika paket diterima lebih dari satu hari setelah estimasi. Setelah definisi disepakati, label target perlu dibentuk ulang secara konsisten. Business Understanding memang bertugas menerjemahkan kebutuhan menjadi target dan metrik yang jelas. **[ML-P02, hlm. 6–7]**

1. **`tanggal_diterima` dipakai sebagai fitur input**

Kembali ke **Data Understanding** untuk mengidentifikasi bahwa kolom tersebut hanya tersedia setelah paket sampai, kemudian ke **Data Preparation** untuk membuangnya dari fitur, membangun ulang pipeline, dan melatih serta mengevaluasi model kembali. Kolom tersebut merupakan target leakage karena memakai informasi masa depan. **[ML-P02, hlm. 8–9, 18]**

## c. Stratified train–validation–test

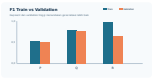
Rasio pembagian adalah 70% : 10% : 20%. Stratifikasi menjaga rasio kelas pada setiap subset. **[ML-P02, hlm. 14–17]**

| Subset | Tepat waktu | Terlambat | Total |
|---|---|---|---|
| Train (70%) | 0,70 × 8.800 = **6.160** | 0,70 × 1.200 = **840** | **7.000** |
| Validation (10%) | 0,10 × 8.800 = **880** | 0,10 × 1.200 = **120** | **1.000** |
| Test (20%) | 0,20 × 8.800 = **1.760** | 0,20 × 1.200 = **240** | **2.000** |

Fungsi setiap subset:

- **Train:** mempelajari parameter model dan melakukan fit preprocessing.
- **Validation:** memilih model, hyperparameter, threshold, dan tindakan penanganan imbalance.
- **Test:** mengukur performa akhir satu kali setelah seluruh pilihan selesai.

### d. Diagnosis tiga model

 Model Q memiliki F1 validation tertinggi dengan gap yang tetap kecil.

Gap dihitung dengan `F1_train − F1_validation`.

| Model | F1 train | F1 validation | Gap | Diagnosis |
|---|---|---|---|---|
| P | 0,520 | 0,510 | **0,010** | Keduanya rendah dan berdekatan: **underfitting/high bias** |
| Q | 0,800 | 0,770 | **0,030** | Skor relatif tinggi dengan gap kecil: generalisasi terbaik |
| R | 0,970 | 0,650 | **0,320** | Train sangat tinggi, validation jauh lebih rendah: **overfitting/high variance** |

Tindakan untuk **P**: tambah kapasitas model atau perbaiki fitur agar pola yang relevan dapat dipelajari. Tindakan untuk **R**: kurangi kompleksitas/beri regularisasi; alternatifnya tambah data train. Model yang dilanjutkan adalah **Q**, karena F1 validation tertinggi dengan gap kecil. Diagnosis ini mengikuti ciri high bias dan high variance pada learning curve. **[ML-P02, hlm. 19–21]**

# 2. Data Preparation dan Imbalanced Data

### a. IQR berat paket

Data terurut: 1, 2, 2, 3, 3, 4, 5, 18.

Dengan metode median dari masing-masing separuh data:

$$Q_1=(2+2)/(2)=2,000$$

$$Q_3=(4+5)/(2)=4,500$$

$$IQR=Q_3-Q_1=4,500-2,000=2,500$$

$$\text{Batas bawah}=Q_1-1,5(IQR)=2-3,75=-1,750$$

$$\text{Batas atas}=Q_3+1,5(IQR)=4,5+3,75=8,250$$

Nilai **18 kg** adalah kandidat outlier karena 18 > 8,250. Nilai tersebut tidak boleh langsung dihapus. Periksa dulu apakah terjadi salah input/salah satuan. Jika paket 18 kg valid dan memang mungkin terjadi dalam operasi, nilainya sebaiknya dipertahankan atau ditangani dengan transformasi/metode robust karena menghapusnya dapat membuang fenomena penting. **[ML-P03, hlm. 11–15]**

## b. Imputasi dan Z-score

Nilai jarak yang tersedia: 5, 8, 10, 12, 65.

$$\text{Mean}=(5+8+10+12+65)/(5)=(100)/(5)=20,000 \text{ km}$$

Median dari data terurut 5, 8, 10, 12, 65 adalah **10,000 km**.

Imputasi yang lebih tepat adalah **median**, karena distribusi miring akibat nilai 65 dan median lebih tahan terhadap nilai ekstrem. **[ML-P03, hlm. 9]**

Untuk paket 55 km:

$$z=(x-\mu)/(\sigma)=(55-15)/(12)=(40)/(12)=3,333$$

Karena |3,333|>3, jarak 55 km merupakan **kandidat outlier**. Status kandidat tidak otomatis berarti nilai harus dihapus. **[ML-P03, hlm. 14–15]**

## c. Class weight

Pada data train: N = 7.000, K = 2, `n_tepat_waktu` = 6.160, dan `n_terlambat` = 840.

$$w_{tepat}=(7.000)/(2\times6.160)=0,568$$

$$w_{terlambat}=(7.000)/(2\times840)=4,167$$

Perbandingannya:

$$\frac{w_{terlambat}}{w_{tepat}}=\frac{4,167}{0,568}=7,333$$

Artinya, kesalahan pada satu paket terlambat diberi penalti sekitar **7,333 kali** kesalahan pada satu paket tepat waktu. Dengan demikian model lebih memperhatikan kelas minoritas tanpa menggandakan atau menghapus data. **[ML-P03, hlm. 22–23]**

### d. SMOTE

Diketahui:

$$x_i=(2,7),\ x_j=(8,4),\ \lambda=(1)/(3)$$

$$x_j-x_i=(8-2,4-7)=(6,-3)$$

$$x_{baru}=(2,7)+(1)/(3)(6,-3)=(2,7)+(2,-1)=(4,6)$$

SMOTE hanya diterapkan pada data train agar informasi sintetis dari kelas minoritas tidak masuk ke validation/test. Jika dilakukan sebelum split, sampel yang saling berkaitan dapat tersebar ke subset evaluasi dan menghasilkan data leakage serta skor yang terlalu optimistis. **[ML-P03, hlm. 20–21, 24–25]**

## 3. Feature Selection dan Feature Engineering

### a. Uji chi-square

Total baris = 200, total terlambat = 50, dan total tepat waktu = 150. Karena setiap baris tabel memiliki total 100, frekuensi harapan untuk masing-masing baris adalah:

$$E_{terlambat}=(100\times50)/(200)=25$$

$$E_{tepat}=(100\times150)/(200)=75$$

| Sel | O | E | $(O-E)^2/E$ |
|---|---|---|---|
| Ekonomi=Ya, Terlambat | 36 | 25 | 4,840 |
| Ekonomi=Ya, Tepat | 64 | 75 | 1,613 |
| Ekonomi=Tidak, Terlambat | 14 | 25 | 4,840 |
| Ekonomi=Tidak, Tepat | 86 | 75 | 1,613 |

$$\chi^2=4,840+1,613+4,840+1,613=12,907$$

Karena **12,907 > 3,840**, H0 independensi ditolak pada α = 0,05. Ada hubungan signifikan antara layanan ekonomi dan keterlambatan, sehingga fitur **layanan ekonomi layak dipertahankan**. Chi-square membandingkan frekuensi observasi dengan frekuensi harapan; selisih yang makin besar mengindikasikan hubungan yang lebih kuat. **[ML-P04, hlm. 14]**

## b. Rancangan ColumnTransformer

Rancangan preprocessing:

| Kelompok | Kolom | Perlakuan |
|---|---|---|
| Numerik biasa | `berat_kg` | `SimpleImputer(strategy="median")`, kemudian `StandardScaler()` |
| Numerik miring | `jarak_km` | imputasi median, transformasi `log1p` bila seluruh nilai nonnegatif, lalu `RobustScaler()` atau `StandardScaler()` |
| Nominal | `kota_tujuan`, `jenis_layanan` | imputasi modus, lalu `OneHotEncoder(handle_unknown="ignore")` |
| Ordinal | `tingkat_prioritas` | imputasi modus, lalu `OrdinalEncoder` dengan |

| Kelompok | Kolom | Perlakuan |
|---|---|---|
| | | urutan `rendah < sedang < tinggi` |
| Timestamp | `waktu_pemesanan` | ekstrak fitur waktu, lalu buang timestamp mentah |

Dua fitur baru yang diusulkan:

1. **`jam_pemesanan`**, untuk menangkap pola keterlambatan berdasarkan jam sibuk atau jam operasional.
2. **`is_akhir_pekan`**, bernilai 1 untuk Sabtu/Minggu dan 0 selainnya, untuk menangkap perbedaan kapasitas operasional akhir pekan.

Kolom **`tanggal_diterima` wajib dibuang**, karena baru tersedia setelah paket sampai. Memakainya saat memprediksi keterlambatan berarti menggunakan informasi masa depan dan menimbulkan leakage. Timestamp memang sebaiknya diubah menjadi pola waktu, ColumnTransformer memberi jalur berbeda untuk numerik, nominal, dan ordinal, sedangkan fitur masa depan harus dibuang. **[ML-P04, hlm. 8–9, 20, 23]**

# 4. Decision Tree

## a. Gini impurity

Node induk mempunyai 6 terlambat dan 14 tepat waktu:

```
Gini(parent)=1-((6)/(20))^2-((14)/(20))^2=0,420
```

**Kandidat X — cuaca buruk di rute**

Cabang Ya (4 terlambat, 1 tepat):

```
Gini(X_Ya)=1-(4/5)^2-(1/5)^2=0,320
```

Cabang Tidak (2 terlambat, 13 tepat):

```
Gini(X_Tidak)=1-(2/15)^2-(13/15)^2=0,231
```

$$Gini_tertimbang(X)=(5)/(20)(0,320)+(15)/(20)(0,231)=0,253$$

**Kandidat Y — layanan ekonomi**

Cabang Ya (4 terlambat, 6 tepat):

$$Gini(Y_Ya)=1-(4/10)^2-(6/10)^2=0,480$$

Cabang Tidak (2 terlambat, 8 tepat):

$$Gini(Y_Tidak)=1-(2/10)^2-(8/10)^2=0,320$$

$$Gini_tertimbang(Y)=(10)/(20)(0,480)+(10)/(20)(0,320)=0,400$$

CART memilih **X (cuaca buruk di rute)** karena Gini tertimbangnya paling kecil, yaitu 0,253. Semakin kecil Gini, semakin homogen node hasil split. **[ML-P05, hlm. 7–8]**

## b. Entropy dan Information Gain

Entropy induk:

$$H(parent)=-0,3log_2(0,3)-0,7log_2(0,7)=0,881$$

**Kandidat X**

$$H(X_Ya)=H(4/5,1/5)=0,722$$

$$H(X_Tidak)=H(2/15,13/15)=0,567$$

$$H_tertimbang(X)=(5)/(20)(0,722)+(15)/(20)(0,567)=0,605$$

$$IG(X)=0,881-0,605=0,276$$

**Kandidat Y**

$$H(Y_Ya)=H(4/10,6/10)=0,971$$

$$H(Y_Tidak)=H(2/10,8/10)=0,722$$

```
H_tertimbang(Y)=(10)/(20)(0,971)+(10)/(20)(0,722)=0,846
```

```
IG(Y)=0,881-0,846=0,035
```

ID3 juga memilih **X**, karena Information Gain X = 0,276 lebih besar daripada Y = 0,035. Information Gain memilih split dengan penurunan entropy terbesar. **[ML-P05, hlm. 9–12]**

## c. Cost-complexity pruning

Untuk α = 0,004:

| Pohon | Perhitungan Cα(T) | Nilai |
|---|---|---|
| T1 | 0,11 + 0,004(22) | 0,198 |
| T2 | 0,15 + 0,004(8) | **0,182** |
| T3 | 0,23 + 0,004(3) | 0,242 |

Pohon terpilih adalah **T2 dengan Cα = 0,182**.

Untuk α = 0,025:

| Pohon | Perhitungan Cα(T) | Nilai |
|---|---|---|
| T1 | 0,11 + 0,025(22) | 0,660 |
| T2 | 0,15 + 0,025(8) | 0,350 |
| T3 | 0,23 + 0,025(3) | **0,305** |

Pohon terpilih adalah **T3 dengan Cα = 0,305**. Ketika α meningkat, penalti untuk banyak leaf makin besar sehingga pohon yang lebih sederhana lebih disukai. Dampaknya adalah **bias cenderung naik** dan **variance cenderung turun**. **[ML-P05, hlm. 18–19]**

### d. Validation curve max_depth


Validation mencapai puncak pada max_depth = 3 lalu menurun.

Nilai validation tertinggi adalah **0,810 pada `max_depth = 3`**, sehingga depth terbaik adalah 3.

- **Depth 1:** train = 0,690 dan validation = 0,680. Keduanya rendah dengan gap 0,010, sehingga model underfitting/high bias.
- **Depth 10:** train = 0,990 dan validation = 0,700. Gap 0,290 sangat besar, sehingga model overfitting/high variance.

Depth dipilih dari puncak performa validation sebelum gap melebar, bukan dari akurasi train tertinggi. **[ML-P05, hlm. 20]**

## 5. K-Nearest Neighbors

Data baru adalah q = (3, 5). Label data latih: D1 terlambat; D2 tepat waktu; D3 tepat waktu; D4 terlambat; D5 tepat waktu.

### a. Euclidean dan weighted KNN

Rumus Euclidean:

$$d(q,D_i)=\sqrt{((x_q-x_i)^2+(y_q-y_i)^2)}$$

| Data | Perhitungan | Jarak | Kelas | Bobot 1/d |
|---|---|---|---|---|
| D1 (4,6) | √[(3−4)²+(5−6)²] | **1,414** | Terlambat | 0,707 |
| D2 (6,9) | √[(3−6)²+(5−9)²] | **5,000** | Tepat waktu | 0,200 |
| D3 (0,1) | √[(3−0)²+(5−1)²] | **5,000** | Tepat waktu | 0,200 |
| D4 | √[(3−9)²+(5−13)² | **10,00** | Terlambat | 0,100 |

| Data | Perhitungan | Jarak | Kelas | Bobot 1/d |
|---|---|---|---|---|
| (9,13) | ] | **0** | | |
| D5 (3,17) | $\sqrt{[(3-3)^2+(5-17)^2}$ ] | **12,000** | Tepat waktu | 0,083 |

Tiga tetangga terdekat adalah D1, D2, dan D3.

- **Voting mayoritas:** tepat waktu mendapat 2 suara dan terlambat 1 suara, sehingga prediksi = **tepat waktu**.
- **Weighted voting:** skor terlambat = 0,707; skor tepat waktu = 0,200 + 0,200 = 0,400. Prediksi = **terlambat**.

Keputusan **berubah**, karena D1 yang terlambat jauh lebih dekat daripada D2 dan D3. Weighted KNN memang memberi pengaruh lebih besar pada tetangga yang dekat. **[ML-P06, hlm. 4–7, 12]**

## b. Manhattan

Rumus Manhattan:

$$d(q,D_i)=|x_q-x_i|+|y_q-y_i|$$

| Data | Jarak Manhattan | Kelas | Bobot 1/d |
|---|---|---|---|
| D1 | **2,000** | Terlambat | 0,500 |
| D2 | **7,000** | Tepat waktu | 0,143 |
| D3 | **7,000** | Tepat waktu | 0,143 |
| D5 | **12,000** | Tepat waktu | 0,083 |
| D4 | **14,000** | Terlambat | 0,071 |

Tiga tetangga terdekat tetap D1, D2, dan D3.

- Voting mayoritas tetap menghasilkan **tepat waktu**.
- Weighted voting: terlambat = 0,500 dan tepat waktu = 0,143 + 0,143 = 0,286, sehingga tetap menghasilkan **terlambat**.

Jadi, urutan tiga tetangga dan kedua prediksi **tidak berubah** dari hasil Euclidean. Metrik Euclidean dan Manhattan memiliki rumus berbeda dan pada dataset lain dapat menghasilkan tetangga berbeda. **[ML-P06, hlm. 6–8]**

## c. Memilih k


Rata-rata akurasi CV tertinggi terjadi pada k = 7.

Rata-rata akurasi cross-validation tertinggi adalah **0,860 pada k = 7**, sehingga k terbaik adalah **7**.

- **k = 1:** akurasi train = 1,000 tetapi CV = 0,770. Model sangat sensitif terhadap data lokal/noise, sehingga mengalami overfitting dan high variance.
- **k = 21:** train = 0,800 dan CV = 0,780. Nilai k yang besar membuat batas keputusan terlalu halus dan pola lokal hilang, sehingga mengarah ke underfitting/high bias.

k tidak dipilih dari akurasi train karena k = 1 dapat menghafal data train dan menghasilkan akurasi 1,000 tanpa menjamin generalisasi. Hyperparameter k harus dipilih menggunakan cross-validation pada data train. **[ML-P06, hlm. 11]**

## d. Alasan scaling

KNN menghitung kedekatan langsung dari selisih nilai fitur. Jika skala fitur berbeda, fitur dengan rentang angka besar akan mendominasi jarak walaupun belum tentu paling penting. Misalnya, `jarak_km` dapat bernilai puluhan atau ratusan, sedangkan skor beban gudang mungkin hanya berada pada skala kecil; tanpa scaling, perubahan jarak akan mengalahkan kontribusi beban gudang.

Karena itu fitur perlu distandardisasi agar keduanya dibandingkan dalam satuan yang sebanding. Scaler harus di-fit hanya pada data train untuk menghindari leakage. **[ML-P06, hlm. 9–10]**

# Kesimpulan Singkat

Kasus KirimCepat membutuhkan evaluasi yang berfokus pada kelas terlambat, preprocessing bebas leakage, serta validasi model yang mempertimbangkan imbalance dan generalisasi. Dari perhitungan yang diberikan, model Q paling layak diteruskan, cuaca buruk menjadi split Decision Tree terbaik, `max_depth = 3` dan `k = 7` menjadi pilihan berdasarkan validation/CV, sedangkan weighted KNN mengubah prediksi paket baru menjadi terlambat karena tetangga terdekat memiliki bobot dominan.

Sumber utama: ML-P02, ML-P03, ML-P04, ML-P05, dan ML-P06. Angka dihitung ulang dan dibulatkan hingga tiga desimal.